SDBench

Microsoft SDBench의 합성 증례 0번을 감사했습니다. 진단 모델(의사)로 돌린 GPT-5와 Astra max는 둘 다 4/5로 통과했습니다. 둘 다 림프종(IVLBCL)은 맞혔지만 동반된 HLH를 빠뜨렸습니다. 그 점수에 이르는 과정에서 문제 8건을 찾았습니다. Gatekeeper가 무엇을 알려주거나 만들어내는지, 묶음 주문을 어떻게 처리하는지, Judge가 무엇을 확인하는지에 관한 것입니다. 각 항목을 펼치면 시험한 조합마다 어떻게 동작했는지 볼 수 있습니다. 실제 실행에서 틀린 작업이 점수를 받은 사례는 없어서, 지금까지 P0는 없습니다.

Audited source · 304ce9625a04 ↗ 실행 2026-10-25 (GPT-5), 2026-10-29 (Astra max) · 합성 증례 5개 중 1개 PDF

● 확인됨: 문제가 나타남 ● 안 나타남: 시험했지만 문제 없음 ○ 이 조합에서는 시험 안 함

요청하지 않은 면역조직화학 패널이 피부생검 결과로 반환됨 피부생검

요청 범위 초과 | 요청 항목 미보고 P1

● GPT-5 ● Astra max ● Astra Gatekeeper

이 증례에서 진단을 확정한 검사가 피부생검입니다. 결과에 무엇이 담기는지는 의사가 무엇을 요청했느냐에 달려 있어야 합니다.

● GPT-5 실행

의사 GPT-5 · Gatekeeper GPT-5 · 실제 실행, 2026-10-25

GPT-5는 깊은 punch 생검과 H&E, 직접면역형광, 세균·진균·항산균 염색을 요청했습니다. CD20·PAX5·Ki-67·EBER는 요청하지 않았습니다. 그런데 Gatekeeper는 원문의 면역조직화학 결과를 함께 돌려줬고, 정작 요청한 면역형광과 염색은 “not reported”로 답했습니다. 응답은 `is_synthetic: false`로 기록됐습니다.

요청과 응답

의사가 요청한 내용 GPT-5 · /test_logs/53/test_name

```
Dermatology punch biopsies of the mottled/telangiectatic skin lesions (deep punch to
subcutis) for H&E and direct immunofluorescence; include bacterial/fungal/AFB stains
```

Gatekeeper가 반환한 내용 GPT-5 · /test_logs/53/result · is_synthetic: false

Dermatology deep punch biopsies (livedoid/telangiectatic lesions and clinically normal skin): Epidermis unremarkable. Numerous small vessels in deep dermis and subcutis (capillaries, postcapillary venules, small arterioles) are distended/occluded by cohesive aggregates of large atypical mononuclear cells with scant cytoplasm, vesicular nuclei, prominent nucleoli; mitoses frequent; occasional intraluminal fibrin thrombi. Minimal perivascular inflammation; atypical cells confined intraluminally. Similar findings present in biopsy of normal-appearing skin.

Immunohistochemistry: Atypical intraluminal cells positive for CD20, PAX5, CD79a; negative for CD3 and cytokeratin. Endothelial markers (CD31/CD34) highlight endothelium encasing intraluminal aggregates. Cells express MUM1/IRF4 and BCL2; CD10 negative; BCL6 weak; subset CD5 positive. Ki-67 proliferation index approximately 95%. EBER in-situ hybridization: negative. Direct immunofluorescence and special stains for bacteria/fungi/AFB: not reported.

로그 JSON 원문


```
{
  "test_name": "Test to order: Dermatology punch biopsies of the mottled/telangiectatic skin lesions (deep punch to subcutis) for H&E and direct immunofluorescence; include bacterial/fungal/AFB stains",
  "reason": "",
  "result": "Dermatology deep punch biopsies (livedoid/telangiectatic lesions and clinically normal skin): Epidermis unremarkable. Numerous small vessels in deep dermis and subcutis (capillaries, postcapillary venules, small arterioles) are distended/occluded by cohesive aggregates of large atypical mononuclear cells with scant cytoplasm, vesicular nuclei, prominent nucleoli; mitoses frequent; occasional intraluminal fibrin thrombi. Minimal perivascular inflammation; atypical cells confined intraluminally. Similar findings present in biopsy of normal-appearing skin.\n\nImmunohistochemistry: Atypical intraluminal cells positive for CD20, PAX5, CD79a; negative for CD3 and cytokeratin. Endothelial markers (CD31/CD34) highlight endothelium encasing intraluminal aggregates. Cells express MUM1/IRF4 and BCL2; CD10 negative; BCL6 weak; subset CD5 positive. Ki-67 proliferation index approximately 95%. EBER in-situ hybridization: negative. Direct immunofluorescence and special stains for bacteria/fungi/AFB: not reported.",
  "is_synthetic": false,
  "timestamp": "2026-10-25T18:41:25.721187",
  "batch_mode": true
}
```


Astra max 실행

의사 Astra max · Gatekeeper GPT-5 · 실제 실행, 2026-10-29

Astra는 CD20·PAX5·CD3·CD31/CD34·Ki-67을 직접 지정해서 요청했습니다. 같은 GPT-5 Gatekeeper가 이번에는 “Immunohistochemistry (requested markers)”라는 제목으로 그

표지자만 돌려줬고, 패널의 나머지는 주지 않았습니다. 같은 Gatekeeper가 두 실행에서 경계를 다르게 그은 셈입니다.

요청과 응답

의사가 요청한 내용 Astra max · /test_logs/14/test_name

```
Obtain three deep skin biopsies, sampling the mottled/telangiectatic areas and clinically normal skin, with each specimen including subcutaneous fat. Request histopathology and immunohistochemistry including CD20, PAX5, CD3, CD31/CD34, and Ki-67, specifically assessing for atypical lymphoid cells within small-vessel lumina.
```

Gatekeeper가 반환한 내용 GPT-5 · /test_logs/14/result · is_synthetic: false

```
Random deep skin biopsies (thigh livedoid area, trunk telangiectatic patch, and clinically normal upper arm), each extending into subcutaneous fat:

Histopathology: Epidermis unremarkable. Numerous dilated small vessels in the deep dermis and subcutaneous fat (capillaries, postcapillary venules, small arterioles) are distended and largely occluded by cohesive aggregates of large atypical mononuclear cells. The atypical cells are intraluminal; minimal infiltration of surrounding stroma. Mitotic figures are frequent; apoptotic debris present. Fibrin thrombi noted in several involved vessels. Similar intravascular aggregates are present in the specimen from clinically normal-appearing skin.

Immunohistochemistry (requested markers): The intraluminal large cells are strongly positive for CD20 and PAX5; negative for CD3. Endothelial markers CD31 and CD34 highlight a thin rim of endothelium surrounding the intraluminal aggregates, confirming localization within vascular lumina. Ki-67 proliferation index is approximately 95%.
```

Raw: astra-max-diagnosis/json/case_k0_0.json

Astra Gatekeeper

GPT-5의 저장된 주문을 Astra Gatekeeper에 다시 보냄 · 재생, 진단·Judge 없음

GPT-5의 주문을 그대로 받은 Astra Gatekeeper는 면역조직화학 패널 없이 원문의 조직 소견만 돌려줬습니다. 요청된 면역형광과 염색은 “Synthetic ancillary results”라는 별도 제목 아래 생성해서 줬습니다. 각 조합을 한 번씩만 돌려서, 이 차이가 모델 때문인지 실행마다의 변동 때문인지는 가를 수 없습니다.

Astra Gatekeeper 응답

```
Documented histologic findings: Numerous dilated small vessels in the deep dermis and within the subcutaneous fat — capillaries, postcapillary venules, and small arterioles — were distended and largely occluded by cohesive aggregates of large, atypical mononuclear cells.
```

```
These cells had scant cytoplasm, large vesicular nuclei with coarse chromatin, and one or
more prominent nucleoli; mitotic figures were frequent, and apoptotic debris was present.
Admixed fibrin thrombi were noted within several involved vessels. There was minimal
infiltration of the surrounding dermal or subcutaneous stroma.
Synthetic ancillary results: Direct immunofluorescence showed no specific vascular or
dermoepidermal immune deposits. Bacterial, fungal, and acid-fast stains showed no organisms.
```

Raw: astra-gatekeeper/replay/comparison.json

패널은 원문에 있는 내용입니다

지어낸 결과는 아닙니다. B세포 표지자, 약 95%의 Ki-67, EBER 음성을 포함한 패널 전체가 원문에 있습니다. 문제는 범위, 즉 어떤 결과가 어떤 주문에 속하느냐입니다.

▾ 원본 case report

> Immunohistochemical staining established the lineage and localization of these cells. The atypical intraluminal cells were strongly positive for the B-cell markers CD20, PAX5, and CD79a, and were negative for the T-cell marker CD3 and for cytokeratin, excluding a carcinoma. Endothelial markers, CD31 and CD34, decorated a thin rim of endothelium surrounding the neoplastic aggregates, confirming unequivocally that the malignant cells resided *within* the vascular lumina rather than in the perivascular tissue. The cells expressed MUM1/IRF4 and BCL2 and were negative for CD10, with only weak BCL6 expression, indicating a non–germinal-center (activated B-cell–like) immunophenotype. CD5 was expressed by a subset of cells. The proliferation index, assessed by Ki-67, was very high, at approximately 95%. In-situ hybridization for Epstein–Barr virus–encoded RNA (EBER) was negative.

Gatekeeper 지시문 안에서도 기준이 갈립니다

프롬프트는 요청 범위를 넘어 진단을 드러내는 정보를 금지하면서, 원문에 있는 검사는 리포트를 그대로 돌려주라고도 합니다. 생검 주문에 어떤 부속 검사가 포함되는지는 정의돼 있지 않아서, 명백한 규칙 위반으로 단정할 수는 없습니다.

▾ Gatekeeper 프롬프트 · v6_fixed

> **Prohibited disclosures** – never reveal or imply: … any information *beyond what is requested* that identifies the diagnosis (e.g. "consistent with X" or "suggestive of X")

> If the investigation already exists in the vignette → return its report verbatim.

평가에 왜 문제가 될 수 있나

요청한 검사만 돌려줘야 한다면 GPT-5 실행은 범위를 넘었습니다. 생검 주문에 병리과의 후속 패널이 포함된다고 본다면, 그 범위와 비용을 모든 참가자에게 똑같이 적용해야 합니다. 지금은 같은 Gatekeeper가 한 의사에게는 묻지 않은 패널 전체를 주고, 다른 의사에게는 요청한 것만 줬습니다. 검사가 임상적으로 부적절하다는 주장은 아닙니다.

CSF 세포검사를 요청했는데 flow cytometry 결과까지 반환됨 요추천자

요청 범위 초과 | 요청 항목 미보고 P1

● GPT-5 ○ Astra max ● Astra Gatekeeper

세포검사(cytology)와 유세포분석(flow cytometry)은 서로 다른 CSF 검사입니다. 요청된 건 세포검사뿐이었습니다.

● GPT-5 실행

의사 GPT-5 · Gatekeeper GPT-5 · 실제 실행, 2026-10-25

GPT-5는 개방압, 세포수, 단백·당, 그람염색·배양, 바이러스 PCR, 크립토코쿠스 항원, 진균·항산균 검사, 그리고 마지막으로 CSF 세포검사를 요청했습니다. Gatekeeper는 `CSF flow cytometry: no clonal lymphoid population.`을 덧붙였습니다. 반면 요청한 enterovirus PCR, 진균 배양, 항산균 검사는 “not reported in the current record”로 답했고, 이 셋은 원문에 없습니다. 응답은 `is_synthetic: false`로 기록됐습니다.

요청과 응답

의사가 요청한 내용 GPT-5 · /test_logs/52/test_name

```
Lumbar puncture after neuroimaging: opening pressure; CSF cell count with differential, protein, glucose; Gram stain and bacterial culture; HSV-1/2 PCR; VZV PCR; enterovirus PCR; cryptococcal antigen; fungal culture; AFB smear/culture; CSF cytology
```

Gatekeeper가 반환한 내용 GPT-5 · /test_logs/52/result · is_synthetic: false

```
Lumbar puncture: Opening pressure 17 cm H2O. CSF: 14 nucleated cells/µL (90% lymphocytes), 2 red cells/µL; protein 76 mg/dL; glucose 64 mg/dL with simultaneous serum glucose 102 mg/dL. Gram stain: no organisms; bacterial cultures: no growth. HSV-1/2 PCR: negative; VZV PCR: negative; cryptococcal antigen: negative. CSF cytology: reactive lymphocytes, no malignant cells. CSF flow cytometry: no clonal lymphoid population. Enterovirus PCR, fungal culture, and AFB smear/culture: not reported in the current record.
```

로그 JSON 원문

```
{
  "test_name": "Test to order: Lumbar puncture after neuroimaging: opening pressure; CSF cell count with differential, protein, glucose; Gram stain and bacterial culture; HSV-1/2 PCR; VZV PCR; enterovirus PCR; cryptococcal antigen; fungal culture; AFB smear/culture; CSF cytology",
  "reason": "",
  "result": "Lumbar puncture: Opening pressure 17 cm H2O. CSF: 14 nucleated cells/µL (90% lymphocytes), 2 red cells/µL; protein 76 mg/dL; glucose 64 mg/dL with simultaneous serum glucose 102 mg/dL. Gram stain: no organisms; bacterial cultures: no growth. HSV-1/2 PCR: negative; VZV PCR: negative; cryptococcal antigen: negative. CSF cytology: reactive lymphocytes, no malignant cells. CSF flow cytometry: no clonal lymphoid population. Enterovirus PCR, fungal culture, and AFB smear/culture: not reported in the current record.",
  "is_synthetic": false,
  "timestamp": "2026-10-25T18:41:25.721185",
  "batch_mode": true
}
```


○ Astra max 실행

의사 Astra max · Gatekeeper GPT-5 · 실제 실행, 2026-10-29

Astra는 요추천자를 주문하지 않았습니다. 대신 flow cytometry를 포함한 CSF 결과가 포괄 질문 하나로 들어왔습니다(아래 포괄 질문 항목 참고).

● Astra Gatekeeper

GPT-5의 저장된 주문을 Astra Gatekeeper에 다시 보냄 · 재생, 진단·Judge 없음

같은 주문을 받은 Astra Gatekeeper는 flow cytometry 없이 원문의 CSF 결과만 돌려줬습니다. enterovirus PCR, 진균 배양, 항산균 검사는 “Synthetic additional results”라는 제목 아래 음성 결과를 생성했습니다.

▾ Astra Gatekeeper 응답

```
Documented results: Opening pressure, 17 cm of water. CSF contained 14 nucleated cells per cubic millimeter (90% lymphocytes) and 2 red cells per cubic millimeter; protein, 76 mg/dL; glucose, 64 mg/dL, with simultaneous serum glucose of 102 mg/dL. Gram staining and bacterial cultures were negative, as were PCR assays for herpes simplex virus and varicella-zoster virus and a cryptococcal antigen assay. CSF cytologic examination revealed reactive lymphocytes but no malignant cells.
Synthetic additional results: Enterovirus PCR negative. Fungal culture showed no growth after final incubation. AFB smear negative; mycobacterial culture showed no growth after final incubation.
```

Raw: astra-gatekeeper/replay/comparison.json

flow cytometry 결과는 원문에 있습니다

원문은 CSF 세포검사와 flow cytometry를 한 문장에 함께 적고 있습니다. Gatekeeper는 하나만 요청한 주문에 둘 다 돌려줬습니다.

원본 case report

> A diagnostic lumbar puncture was performed. The opening pressure was 17 cm of water. The cerebrospinal fluid (CSF) contained 14 nucleated cells per cubic millimeter (90% lymphocytes) and 2 red cells per cubic millimeter; the protein level was 76 mg/dL (reference range, 15–45) and the glucose level was 64 mg/dL with a simultaneous serum glucose of 102 mg/dL. Gram staining and bacterial cultures were negative, as were polymerase-chain-reaction assays for herpes simplex virus and varicella–zoster virus and a cryptococcal antigen assay. CSF cytologic examination revealed reactive lymphocytes but no malignant cells, and flow cytometry of the CSF identified no clonal lymphoid population.

평가에 왜 문제가 될 수 있나

의사는 고르지 않은 검사의 결과를 받습니다. 벤치마크가 검사 단위의 정보 수집 능력과 비용을 잰다면, 공개되는 내용이 실제 주문과 맞아야 합니다. CSF 검사를 묶음으로 본다면, 포함 항목과 가격을 미리 정해둬야 합니다.

원문에 없는 소변배양 음성 결과가 생성됨 소변배양

원문에 없음 | 원문·생성 혼합 P1

● GPT-5 ○ Astra max ● Astra Gatekeeper

원문에는 소변검사는 있지만 소변배양은 없습니다. 원문에 없는 검사는 그럴듯한 결과를 만들고 표시하라고 프롬프트가 지시합니다.

● GPT-5 실행

의사 GPT-5 · Gatekeeper GPT-5 · 실제 실행, 2026-10-25

GPT-5는 소변검사와 소변배양을 함께 요청했습니다. Gatekeeper는 원문의 소변검사에 생성한 음성 배양 결과를 붙여 돌려줬습니다. 응답 전체에 `is_synthetic: true` 표시가 하나만 붙어서, 어느 줄이 생성된 건지는 알 수 없습니다.

요청과 응답

의사가 요청한 내용 GPT-5 · /test_logs/29/test_name

```
Urinalysis and urine culture
```

Gatekeeper가 반환한 내용 GPT-5 · /test_logs/29/result · is_synthetic: true

```
Urinalysis: Specific gravity 1.015; trace protein; no glucose; no leukocyte esterase or
nitrites; 0–2 RBC/HPF; 0–2 WBC/HPF; no casts.
Urine culture: No growth at 48 hours.
```

로그 JSON 원문


```
{
  "test_name": "Test to order: Urinalysis and urine culture",
  "reason": "",
  "result": "Urinalysis: Specific gravity 1.015; trace protein; no glucose; no leukocyte
esterase or nitrites; 0–2 RBC/HPF; 0–2 WBC/HPF; no casts.\nUrine culture: No growth at 48
hours.",
  "is_synthetic": true,
  "timestamp": "2026-10-25T18:41:25.721160",
  "batch_mode": true
}
```


○ Astra max 실행

의사 Astra max · Gatekeeper GPT-5 · 실제 실행, 2026-10-29

Astra는 소변배양을 주문하지 않았습니다. 소변검사 결과는 배양 없이 포괄 질문으로 들어왔습니다.

● Astra Gatekeeper

GPT-5의 저장된 주문을 Astra Gatekeeper에 다시 보낸 뒤 나눠서 보냄 · 재생, 진단·Judge 없음

Astra Gatekeeper는 묶은 주문을 거부했습니다. 두 요청으로 나눠 보내자 원문의 소변검사를 돌려주고, 음성 배양 결과를 생성해 synthetic으로 표시했습니다.

Astra Gatekeeper 응답

```
Request: Urinalysis
Response: The urinalysis showed a specific gravity of 1.015, trace protein, no glucose, no
leukocyte esterase or nitrites, and 0–2 red cells and 0–2 white cells per high-power field,
without casts.
is_synthetic: false

Request: Urine culture
```

```
Response: Urine culture: No growth after 48 hours.
is_synthetic: true
```

Raw: astra-gatekeeper/replay/split-requests/comparison.json

원문의 배양은 혈액배양입니다

원문의 “three sets of blood cultures”는 혈액배양입니다. 소변배양 결과는 어디에도 없습니다.

▾ 원본 case report

> The urinalysis showed a specific gravity of 1.015, trace protein, no glucose, no leukocyte esterase or nitrites, and 0–2 red cells and 0–2 white cells per high-power field, without casts. Three sets of blood cultures obtained over 48 hours showed no growth. Testing for human immunodeficiency virus (HIV) antigen and antibody was negative; hepatitis B surface antigen, hepatitis B core antibody, and hepatitis C antibody were negative; and a rapid plasma reagin test was nonreactive. Antinuclear antibody, anti–double-stranded DNA antibody, antineutrophil cytoplasmic antibodies (both proteinase-3 and myeloperoxidase specificities), rheumatoid factor, and anti–cyclic citrullinated peptide antibody were all negative or within normal limits. The serum C3 and C4 concentrations were normal. Cryoglobulins were not detected. A lupus anticoagulant assay was negative, and anticardiolipin and anti–β2-glycoprotein I antibodies (IgG and IgM) were within normal limits. Serum and urine protein electrophoresis with immunofixation showed no monoclonal protein. Serologic testing for *Bartonella henselae*, *Coxiella burnetii*, *Brucella* species, and *Borrelia burgdorferi* was negative, as was a tuberculosis interferon-γ release assay.

현재 설정이 허용한 동작입니다

생성은 프롬프트가 시킨 일이라서 구현 오류의 증거는 아닙니다. 남는 문제는 생성된 결과의 타당성과 일관성을 어떻게 보장하느냐는 평가 설계의 문제입니다.

▾ Gatekeeper 프롬프트 · v6_fixed

> Else → fabricate a plausible synthetic result and set `<is_synthetic>true</is_synthetic>`.

평가에 왜 문제가 될 수 있나

생성된 음성 배양 결과 때문에 의사 모델이 요로 감염을 발열 원인 후보에서 낮게 볼 수 있습니다. 이번 실행만으로 실제로 판단이 바뀌었는지는 입증되지 않습니다.

Anaplasma·Ehrlichia 검사에 생성된 음성 결과가 반환됨 `Anaplasma · Ehrlichia`

원문에 없음 P1

GPT-5 Astra max Astra Gatekeeper

원문에는 다른 감염 혈청검사는 나열돼 있지만, 진드기 매개 감염인 Anaplasma와 Ehrlichia는 없습니다.

GPT-5 실행

의사 GPT-5 · Gatekeeper GPT-5 · 실제 실행, 2026-10-25

GPT-5는 두 병원체의 PCR과 혈청검사를 요청했습니다. Gatekeeper는 각각 “PCR: Not detected”와 IgG·IgM 음성을 돌려줬고, `is_synthetic: true`로 표시했습니다.

요청과 응답

의사가 요청한 내용 GPT-5 · /test_logs/43/test_name

```
Anaplasma and Ehrlichia PCR/serology
```

Gatekeeper가 반환한 내용 GPT-5 · /test_logs/43/result · is_synthetic: true

```
Anaplasma phagocytophilum:
- PCR: Not detected
- IgG: Negative
- IgM: Negative
Ehrlichia chaffeensis:
- PCR: Not detected
- IgG: Negative
- IgM: Negative
```

로그 JSON 원문


```
{
  "test_name": "Test to order: Anaplasma and Ehrlichia PCR/serology",
  "reason": "",
  "result": "Anaplasma phagocytophilum:\n- PCR: Not detected\n- IgG: Negative\n- IgM:
Negative\nEhrlichia chaffeensis:\n- PCR: Not detected\n- IgG: Negative\n- IgM: Negative",
  "is_synthetic": true,
  "timestamp": "2026-10-25T18:41:25.721175",
  "batch_mode": true
}
```

○ Astra max 실행

의사 Astra max · Gatekeeper GPT-5 · 실제 실행, 2026-10-29

Astra는 이 검사들을 주문하지 않았습니다. 대신 진드기 노출을 물었고, 답(“no recent tick bites reported”)은 원문과 일치합니다.

● Astra Gatekeeper

GPT-5의 저장된 주문을 Astra Gatekeeper에 다시 보낸 뒤 나눠서 보냄 · 재생, 진단·Judge 없음

Astra Gatekeeper는 묶은 주문을 거부했습니다. 검사 6개로 나눠 묻자 두 병원체 모두 PCR·IgG·IgM 음성 결과를 생성했고, 각각 synthetic으로 표시했습니다. GPT-5의 답에는 없던 역가와 참고 범위까지 붙어 있습니다. 생성 결과가 무엇이어야 하는지 벤치마크 안에서 정해진 것은 없습니다.

▾ Astra Gatekeeper 응답

```
Request: Anaplasma PCR
Response: Anaplasma phagocytophilum PCR, whole blood: Not detected.
is_synthetic: true

Request: Anaplasma IgG serology
Response: Anaplasma phagocytophilum IgG by immunofluorescence: <1:64 (negative; reference:
<1:64).
is_synthetic: true

Request: Anaplasma IgM serology
Response: Anaplasma phagocytophilum IgM antibody: <1:20 (negative; reference: <1:20).
is_synthetic: true

Request: Ehrlichia PCR
Response: Ehrlichia species PCR, whole blood: Not detected.
is_synthetic: true

Request: Ehrlichia IgG serology
Response: Ehrlichia chaffeensis IgG antibody: <1:64 (negative; reference: <1:64).
is_synthetic: true

Request: Ehrlichia IgM serology
Response: Ehrlichia chaffeensis IgM antibody: <1:20 (negative; reference: <1:20).
is_synthetic: true
```

Raw: astra-gatekeeper/replay/split-requests/comparison.json

원문에 있는 감염 검사

원문에는 Bartonella, Coxiella, Brucella, Borrelia 혈청검사와 결핵 IGRA가 있습니다. Anaplasma와 Ehrlichia는 어디에도 없습니다. 없는 결과를 생성하는 건 프롬프트가 허용한 동작입니다.

원본 case report

> ... Serum and urine protein electrophoresis with immunofixation showed no monoclonal protein. Serologic testing for *Bartonella henselae*, *Coxiella burnetii*, *Brucella* species, and *Borrelia burgdorferi* was negative, as was a tuberculosis interferon-γ release assay.

평가에 왜 문제가 될 수 있나

생성된 음성 결과 때문에 의사 모델이 진드기 매개 감염을 감별진단에서 지울 수 있고, Gatekeeper마다 그 결과를 다르게 씁니다. 이번 실행만으로 실제로 판단이 바뀌었는지는 입증되지 않습니다.

포괄 질문 하나로 입원 중 검사 결과와 HLH 지표가 한꺼번에 공개됨 환자 질문

요청 범위 초과 | 규칙 충돌 의심 | P1

○ GPT-5 ● Astra max ○ Astra Gatekeeper

환자 질문은 병력과 증상을 묻는 용도지만, 질문 하나로 원래는 검사별로 주문해야 할 결과까지 물을 수도 있습니다.

○ GPT-5 실행

의사 GPT-5 · Gatekeeper GPT-5 · 실제 실행, 2026-10-25

GPT-5의 질문 18개는 증상, 병력, 노출에 관한 것이었고 이전 검사 결과를 묻는 질문은 없었습니다. 그래서 이 실행에서는 중성지방, sIL-2R, 골수 소견이 의사에게 전달되지 않았습니다.

● Astra max 실행

의사 Astra max · Gatekeeper GPT-5 · 실제 실행, 2026-10-29

Astra는 첫 턴에 질문 9개를 했고, 9번째로 이미 시행한 검사와 그 결과를 물었습니다. GPT-5 Gatekeeper는 이번 입원 중의 혈액검사, CSF, 초기 골수 결과를 한 번에 답했습니다. 여기에는 ferritin 3,150 ng/mL, 중성지방 295 mg/dL, 가용성 IL-2 수용체 4,250 U/mL, 골수 혈구탐식 소견이 들어 있었습니다. 입원 중 영상검사만 빼놨는데, 프롬프트가 영상은 주문 전까지 숨기라고 하기 때문입니다. 혈액검사나 골수 결과에는 그런 규칙이 없습니다. 응답은 `is_synthetic: false`로 기록됐습니다.

그래도 Astra의 최종 답에는 HLH가 없었습니다. 답은 IVLBCL의 CNS·피부·골수 침범이었고, Judge는 HLH와 non–germinal-center 아형 누락으로 1점을 뺐습니다(4/5). 정보가 없어서 HLH를 놓친 건 아니라는 뜻입니다.

질문과 응답

의사가 한 질문 Astra max · 첫 턴 9번째 질문

```
What investigations have already been performed, including blood counts, liver and kidney tests, cultures, brain imaging, or lumbar puncture, and what were the results?
```

Gatekeeper가 반환한 내용 GPT-5 · /test_logs/8/result · is_synthetic: false

```
Investigations to date:
- Hematology: Hgb 9.4 g/dL, Hct 28.5%, MCV 89 fL, WBC 3.6×10⁹/L, platelets 96×10⁹/L, reticulocytes 1.0%; smear: normochromic normocytic anemia, no schistocytes, occasional teardrop forms, no blasts.
- Coagulation: PT 13.1 s, aPTT 31 s, fibrinogen 360 mg/dL, D-dimer 2.9 µg/mL FEU.
- Chemistry/inflammation: AST 76 U/L, ALT 52 U/L, alkaline phosphatase 168 U/L, total bilirubin 1.1 mg/dL, albumin 3.0 g/dL, LDH 842 U/L, haptoglobin 15 mg/dL, ferritin 3,150 ng/mL, triglycerides 295 mg/dL, uric acid 7.8 mg/dL, ESR 88 mm/hr, CRP 96 mg/L, procalcitonin 0.12 ng/mL, soluble IL-2 receptor 4,250 U/mL, β2-microglobulin 4.2 mg/L, lactate 1.4 mmol/L, thyrotropin 2.3 µIU/mL.
- Urinalysis: specific gravity 1.015; trace protein; 0–2 RBC and 0–2 WBC per HPF; no leukocyte esterase or nitrites; no casts.
- Microbiology/serology: three sets of blood cultures—no growth. HIV antigen/antibody negative; hepatitis B surface antigen and core antibody negative; hepatitis C antibody negative; RPR nonreactive. Serologies negative for Bartonella henselae, Coxiella burnetii, Brucella spp., and Borrelia burgdorferi. TB interferon-γ release assay negative.
- Autoimmune panel: ANA, anti-dsDNA, ANCA (PR3/MPO), rheumatoid factor, anti-CCP negative/within normal limits; C3/C4 normal; cryoglobulins not detected; lupus anticoagulant negative; anticardiolipin and anti-β2-glycoprotein I (IgG/IgM) within normal limits; serum/urine protein electrophoresis with immunofixation—no monoclonal protein.
- Lumbar puncture: opening pressure 17 cm H₂O; CSF 14 nucleated cells/mm³ (90% lymphocytes), 2 RBC/mm³; protein 76 mg/dL; glucose 64 mg/dL (serum 102 mg/dL). CSF Gram stain/cultures negative; HSV and VZV PCR negative; cryptococcal antigen negative; cytology with reactive lymphocytes; flow cytometry—no clonal lymphoid population.
- ADAMTS13 activity: 68% (reference >60%).
- Imaging performed during this admission (reports available upon order): CT chest/abdomen/pelvis with contrast; MRI brain with and without contrast; intracranial and cervical MRA; transthoracic and transesophageal echocardiography; whole-body FDG PET-CT.
- Bone marrow: aspirate/biopsy hypercellular for age with trilineage hematopoiesis; increased activated macrophages with hemophagocytosis; no overt sheets of malignant cells on initial aspirate; flow cytometry—no clearly abnormal population.
```

Raw: astra-max-diagnosis/json/case_k0_0.json · API: api_calls/gatekeeper_001.json

○ Astra Gatekeeper

GPT-5의 저장된 주문을 Astra Gatekeeper에 다시 보냄 · 재생, 진단·Judge 없음

재생은 검사 주문만 다시 보냈기 때문에 환자 질문은 시험하지 않았습니다.

주문 하나 없이 진단 관련 소견이 들어왔습니다

프롬프트는 진단을 결정할 수 있는 소견은 표적 검사로만 공개하고, 이 규칙을 어기게 되는 환자 질문은 거부하라고 합니다.

Gatekeeper 프롬프트 · v6_fixed

> Only allow the disclosure of findings that may determine the diagnosis in targeted and specific tests (such as microbiology or viral cultures growing specific organisms, biopsies showing specific cell types, genetic tests revealing specific genetic mutation). Otherwise refuse to disclose the finding and ask the agent to order the specific test.

> If answering would break the Pathognomonic safeguard → refuse with the standard template.

프롬프트는 기록 조회도 허용합니다

다른 규칙은 답이 기록에 있으면 기록에서 답하도록 허용합니다. 이전의 비영상 검사는 진단적이지 않을 때만 상세 결과를 주라고 합니다. 하지만 "지금까지 뭘 했나" 같은 질문을 어디까지 허용할지, 어떤 소견이 진단을 결정하는지는 정해져 있지 않습니다. 그래서 위반이 의심될 뿐 확정은 아닙니다.

Gatekeeper 프롬프트 · v6_fixed

> If the answer exists in the chart → quote it in clinical-documentation style (no first-person quotes).

> **Historic investigations (non-imaging)** – May be acknowledged by type + date; provide details only if documented and non-diagnostic.

평가에 왜 문제가 될 수 있나

Astra의 검사 주문은 7개로 GPT-5의 36개보다 훨씬 적지만, 정보의 상당 부분이 이 질문 하나로 들어왔고 주문 여러 개가 검사나 검체 여러 개를 묶고 있습니다. 두 실행의 주문 수나 검사비를 비교하면 오해를 낳습니다.

원문은 Bartonella 혈청검사 음성 하나뿐인데 IgG·IgM을 각각 음성으로 보고함 `Bartonella 혈청검사`

원문 기반으로 표시 | 과잉 구체화 의심 | P1

GPT-5 Astra max Astra Gatekeeper

`is_synthetic`은 결과가 어디서 왔는지 벤치마크가 남기는 유일한 기록입니다. 원문을 넘어 추론한 내용을 원문 기반으로 표시하면 안 됩니다.

GPT-5 실행

의사 GPT-5 · Gatekeeper GPT-5 · 실제 실행, 2026-10-25

GPT-5는 henselae와 quintana의 IgG/IgM, 선택적 PCR을 한 주문으로 요청했습니다. Gatekeeper는 각각 음성으로 답했지만 응답 전체를 synthetic으로 표시해서, 추론한 부분까지 표시가 덮습니다.

요청과 응답

```
Request: Bartonella henselae and quintana serology (IgG/IgM) ± PCR
Response: Bartonella henselae IgG: Negative; IgM: Negative
Bartonella quintana IgG: Negative; IgM: Negative
Bartonella PCR (blood): Not detected
is_synthetic: true
```

Raw: gpt5-trajectory/case_k0_0.json · /test_logs/40

Astra max 실행

의사 Astra max · Gatekeeper GPT-5 · 실제 실행, 2026-10-29

Astra는 Bartonella 검사를 주문하지 않았습니다. 포괄 질문의 답에는 Bartonella henselae 혈청검사 음성이라고만 나와, 원문 표현과 같습니다.

Astra Gatekeeper

Astra Gatekeeper에 나눠서 보낸 요청 · 재생, 진단·Judge 없음

분할 실험(주문 처리 항목 참고)에서 두 요청이 Bartonella henselae IgG와 IgM을 각각 물었습니다. 두 답 모두 “Negative”였고 `is_synthetic: false`였습니다.

요청과 응답

```
Request: Bartonella henselae IgG serology
Response: Bartonella henselae IgG serology: Negative.
is_synthetic: false

Request: Bartonella henselae IgM serology
Response: Bartonella henselae IgM serology: Negative.
is_synthetic: false
```

Raw: astra-gatekeeper/replay/split-requests/comparison.json

추론을 기록된 결과처럼 표시했습니다

"혈청검사 음성"을 "IgG 음성, IgM 음성"으로 나누는 건 그럴듯한 추론이지만 원문에 적힌 내용은 아닙니다. false로 표시돼 있으면 읽는 사람은 둘 다 기록된 결과로 받아들입니다. 다만 어느 값이 임상적으로 틀렸다거나, 실제로 어떤 패널을 돌렸는지는 확인하지 못했습니다.

▾ 원본 case report

> ... Serum and urine protein electrophoresis with immunofixation showed no monoclonal protein. Serologic testing for *Bartonella henselae*, *Coxiella burnetii*, *Brucella* species, and *Borrelia burgdorferi* was negative, as was a tuberculosis interferon-γ release assay.

평가에 왜 문제가 될 수 있나

추론한 내용이 원문 기반으로 표시되면 생성된 정보와 기록된 정보를 구분할 수 없습니다. "혈청검사 음성, IgG/IgM 개별 결과는 기재 없음"이라고 답하는 편이 안전합니다.

Astra Gatekeeper는 묶음 주문 10개를 거부했지만, 같은 검사를 하나씩 보내면 응답함 묶음 주문

▾ 주문 표현에 따라 응답이 달라짐 | 원인 미분리 P1

● GPT-5 ● Astra max ● Astra Gatekeeper

프롬프트는 주문마다 검사 하나를 지정하라고 하지만, 무엇이 검사 하나인지 정한 목록은 없습니다.

● GPT-5 실행

의사 GPT-5 · Gatekeeper GPT-5 · 실제 실행, 2026-10-25

GPT-5 Gatekeeper는 "Rheumatoid factor (RF) and anti-CCP" 같은 묶음 10개를 포함해 주문 36개에 모두 답했습니다.

▾ 예시: RF와 anti-CCP

```
Request: Rheumatoid factor (RF) and anti-CCP
Response: Rheumatoid factor: Within normal limits.
Anti-cyclic citrullinated peptide (anti-CCP): Within normal limits.
is_synthetic: false
```

Astra max 실행

의사 Astra max · Gatekeeper GPT-5 · 실제 실행, 2026-10-29

GPT-5 Gatekeeper는 Astra의 주문 7개에 모두 답했습니다. 그중 몇 개는 두 심초음파나 면역염색을 포함한 피부생검 3건처럼 검사나 검체 여러 개를 묶은 주문이었습니다.

Astra Gatekeeper

GPT-5의 저장된 주문 36개를 Astra Gatekeeper에 다시 보낸 뒤, 거부된 주문을 나눠 보냄 · 재생, 진단·Judge 없음

Astra Gatekeeper(`openai/gpt-6-astra`, 기본 reasoning 설정)는 주문 36개 중 26개에 답하고, 10개는 이유 없이 프롬프트의 정해진 거부 문구로 거부했습니다. 그 10개를 주문 하나씩, 대부분 검사 하나씩인 31개 요청으로 나눠 보내자 31개 모두 답했고 17개를 synthetic으로 표시했습니다. "Rheumatoid factor (RF) and anti-CCP"는 묶어서 보내면 거부했지만, 따로 보내자 각각 원문대로 답했습니다. 반면 여러 염색을 묶은 피부생검 주문은 하나로 받아줬고, 분할 실험에서 일부러 묶어둔 "ENA panel"도 요청 하나로 받아 항체 6종의 결과를 생성했습니다.

▾ 거부된 주문 10개

```
 1. Urinalysis and urine culture
 2. Thyroid-stimulating hormone (TSH) and free T4
 3. Serum protein electrophoresis (SPEP) with immunofixation and serum free light chains
 4. Antinuclear antibody (ANA) with ENA panel and anti-double-stranded DNA
 5. Rheumatoid factor (RF) and anti-CCP
 6. Cryoglobulins and cryofibrinogen
 7. Hepatitis B surface antigen, core antibody; Hepatitis C antibody
 8. Bartonella henselae and quintana serology (IgG/IgM) ± PCR
 9. Anaplasma and Ehrlichia PCR/serology
10. Babesia blood smear and PCR
```

거부 문구 Astra · 10개 모두 동일 · is_synthetic: false

```
I can only provide specific test results or answer specific patient questions. Please request
a specific diagnostic test or ask a specific question about the patient's history, symptoms,
or demographics.
```

▾ RF와 anti-CCP를 따로 물었을 때

```
Request: Rheumatoid factor (RF)
Response: Rheumatoid factor: negative or within normal limits.
is_synthetic: false

Request: Anti-CCP antibody
```

```
Response: Anti-cyclic citrullinated peptide antibody: within normal limits.
is_synthetic: false
```

Raw: replay/comparison.json · split-requests/comparison.json

검사 하나의 기준을 정한 목록이 없습니다

프롬프트는 검사 하나를 지정하라고 하고 포괄 주문은 거부하라고 하지만, 무엇이 검사 하나인지 정한 목록은 없습니다. 또 나눠 보내면서 호출 한 번에 들어간 요청 수도 함께 바뀌어서, 두 요인의 영향을 가를 수 없습니다. 각 조건은 한 번씩만 돌렸습니다.

▾ Gatekeeper 프롬프트 · v6_fixed

> Must name a single orderable investigation performed by a department *unless* the order concerns **routine bedside observations** (see below).

> Refuse umbrella orders (e.g. “all infection tests”, “complete blood work”).

평가에 왜 문제가 될 수 있나

Astra Gatekeeper라면 의사 모델이 결과를 받을지가 어떤 검사를 고르느냐뿐 아니라 주문을 어떻게 쓰고 묶느냐에도 달려 있습니다. 다만 일관성 없는 집행이라고 입증된 건 아닙니다. 염색을 포함한 생검이나 이름 있는 패널은 검사 하나로 볼 여지가 있습니다.

trace에 거짓 설명을 넣어도 5/5를 받음 Judge 실험

▾ 과정은 채점하지 않음 | 직접 만든 답안 P1

● GPT-5 Judge ● Astra max Judge

이 실험은 우리가 직접 만든 것이고, 거짓 문장을 쓴 진단 모델은 없습니다. 저장된 Astra 실행에서 최종 답을 정답 진단 그대로 바꾼 것이 A입니다. 여기에 Judge가 읽는 피부생검 로그의 reason 필드에 거짓 문장을 넣은 것이 C입니다. Judge마다 A와 C를 세 번씩 채점했고, 의사나 Gatekeeper 호출은 없었습니다.

▾ 심은 문장

```
The skin biopsy showed no atypical intravascular cells.
```

실제 생검 결과에는 혈관 내 비정형 세포가 보고돼 있습니다. 같은 문장을 진단 태그 앞 본문에 넣은 B는 Judge가 그 부분을 보지 않아서 A와 입력이 같습니다. Raw: judge-probes/false-intermediate-step/comparison.json

- **GPT-5 Judge**

답안마다 3회 채점

A: 5, 5, 5. C: 5, 5, 5. 채점 설명에서 모순을 명시적으로 언급한 적은 없었습니다.

- **Astra max Judge**

답안마다 3회 채점

A: 5, 5, 5. C: 5, 5, 5. C 채점 중 한 번은 모순을 분명히 짚고도 5/5를 줬습니다.

▾ 채점 설명

> Although the skin-biopsy order contains a contradictory negative-result parenthetical, the **actual reported result** and pathological narrative document diagnostic intravascular malignant B cells.

두 번째 실험에서는 근거 없는 추가를 잡아냈습니다

정답에 근거 없는 "이차성 저감마글로불린혈증"을 덧붙였습니다. 두 Judge 모두 세 번 다 3/5로 깎았고, 정답은 매번 5/5였습니다.

▾ 두 답안

```
A · correct answer
Intravascular large B-cell lymphoma (non-germinal-center B-cell immunophenotype), with
central-nervous-system and cutaneous involvement and associated secondary hemophagocytic
lymphohistiocytosis.

B · with an unsupported addition
Intravascular large B-cell lymphoma (non-germinal-center B-cell immunophenotype), with
central-nervous-system and cutaneous involvement and associated secondary hemophagocytic
lymphohistiocytosis. The lymphoma is also complicated by secondary hypogammaglobulinemia.
```

Raw: judge-probes/unsupported-complication/comparison.json

평가에 왜 문제가 될 수 있나

점수는 최종 진단만 보증하고, 그에 이른 추론이나 과정은 보증하지 않습니다. 채점 기준이 밝힌 범위와 같아서 채점 버그라기보다 범위의 한계입니다. 다만 통과 점수가 trace의 진실성에 대해서는 아무것도 말해주지 않는다는 뜻이기도 합니다.

벤치마크와 채점 방식

SDBench 채점 방식

SDBench는 증례마다 세 역할을 번갈아 돌립니다. 의사 모델은 진단이 드러나지 않은 짧은 증례 요약을 받고, 턴마다 검사를 주문하거나 질문하거나 진단을 확정합니다. Gatekeeper는 증례 원문을 보고 각 요청에 답합니다. 원문에 결과가 있으면 그대로 주고, 없으면 합성 결과를 만들라고 프롬프트가 지시합니다(GPT-5 실행에서는 대신 "not reported"라고 답한 경우도 있었습니다). 의사가 진단을 확정하면 Judge가 정답과 비교해 1–5점을 매기고, 4–5점을 정답으로 칩니다.

Gatekeeper와 Judge는 설정으로 고정되고, 평가 대상은 의사 모델뿐입니다. 그래서 Gatekeeper가 무엇을 알려주느냐가 의사 모델의 점수에 그대로 반영됩니다.

시험한 조합

증례	`synthetic` 데이터셋 · train · case 0 — "Case 17-2026: A 58-Year-Old Woman with Recurrent Fever, Progressive Confusion, and Multifocal Cerebral Infarction". 정답 진단: 혈관내 거대 B세포 림프종(non–germinal-center B세포 면역표현형), 중추신경계·피부 침범, 동반 이차성 혈구탐식성 림프조직구증(HLH).
GPT-5 실행 · 2026-10-25	의사 GPT-5(SDBench 기본 에이전트), Gatekeeper GPT-5, Judge GPT-5. 프롬프트 `v6_fixed` / `v4_reasoning_with_tests`. 환자 질문 18개, 한 턴에 검사 주문 36개, 그다음 진단: IVLBCL의 피부·CNS 침범. 4/5이고, Judge는 non–germinal-center 아형과 HLH 누락을 지적했습니다. 검사 응답 36개 중 10개가 synthetic으로 표시됐습니다.
Astra max 실행 · 2026-10-29	의사 `openai/gpt-6-astra`(max reasoning, 같은 기본 에이전트). Gatekeeper와 Judge는 같은 프롬프트의 GPT-5. 환자 질문 9개, 검사 주문 7개, 그다음 진단: IVLBCL의 CNS·피부·골수 침범. 같은 두 누락으로 4/5였고, Judge는 골수 침범을 맞는 내용으로 인정했습니다. 응답 16개 모두 synthetic 표시가 없었습니다.
Astra Gatekeeper 재생	GPT-5 실행의 저장된 주문 36개를 Gatekeeper로 쓴 `openai/gpt-6-astra`(기본 reasoning)에 그대로 다시 보내고, 거부된 10개를 31개 요청으로 나눠 보냈습니다. 의사 턴과 Judge는 없습니다.
Judge 실험	우리가 작성한 답안을 GPT-5와 Astra max가 각각 세 번씩 채점했습니다. 의사나 Gatekeeper 호출은 없습니다.

is_synthetic 읽는 법

`is_synthetic`은 Gatekeeper 모델이 스스로 붙이는 표시이고, 독립적인 검증이 아닙니다. `false`는 생성 결과가 들어 있다고 표시하지 않았다는 뜻일 뿐, 정확성이나 적절한 범위, 실제 환자 데이터라는 걸 보증하지 않습니다. 거부 응답에도 `false`가 붙습니다. `true`는 생성된 내용이 섞였다는 뜻이지, 응답 전체가 생성됐다는 뜻은 아닙니다. 원문 리포트 자체도 합성 자료입니다.

이번 감사로 말할 수 있는 것

어느 의사 모델도 검사 없이 정상이라고 가정했다는 증거는 아닙니다. 모델은 질문하고 주문했고, Gatekeeper가 추가 정보를 주거나 없는 결과를 만들었습니다. 그게 최종 진단에 얼마나 영향을 줬는지는 이 로그만으로 알 수 없습니다.

두 모델 모두 핵심 질환은 맞혔습니다

둘 다 피부 병리 결과를 받은 뒤 IVLBCL을 답했고, 둘 다 HLH 누락으로 1점을 잃었습니다. GPT-5는 계통을 확정하는 B세포 표지자를 요청하지 않은 패널로 받았고, Astra는 그 패널을 직접 요청했습니다.

지금까지 P0는 없습니다

실제 실행에서 틀린 작업이 점수를 받은 사례는 없습니다. 거짓 설명 결과는 우리가 쓴 답안에서 나온 것입니다.

정보 수집 과정은 검증되지 않습니다

설정된 GPT-5 Gatekeeper는 요청하지 않은 결과를 더하고, 포괄 질문에 진단 관련 소견으로 답하고, 없는 결과를 생성했습니다. Astra Gatekeeper에서는 주문을 어떻게 묶었느냐에 따라 응답 여부가 갈렸고, GPT-5 Gatekeeper는 같은 주문 36개 중 하나도 거부하지 않았습니다.

Gatekeeper가 평가에 영향을 줄 수 있습니다

최종 답에 미친 인과적 영향을 확인하려면, 추가 정보를 빼고 다시 돌리는 것 같은 별도 실험이 필요합니다.

토큰 절약 의도는 확인할 수 없습니다

에이전트 프롬프트에 토큰 목표가 없고, 로그에 검사별 이유도 남지 않습니다(harness가 `reason` 필드를 채우지 않음). 모델의 의도는 추정하지 않습니다.

같은 조건으로 비교하려면

1. 검사 ID마다 돌려줄 결과와 포함할 후속 패널을 정합니다.
2. 환자 질문이 무엇까지 돌려받을 수 있는지 정하고, 표적 검사 규칙을 질문에도 적용합니다.
3. 의사에게 공개한 검사 항목과 비용 산정 항목을 맞춥니다.
4. 원문에 없는 결과는 '자료 없음'으로 처리하거나, 검토해 고정한 값을 모든 참가자에게 똑같이 줍니다.
5. 원문 기반인지 생성인지를 응답 전체가 아니라 세부 검사별로 기록합니다.

비용 추정

GPT-5 실행의 검사와 합성 리포트에 나온 의사의 검사 경로를 같은 자동 방식으로 가격을 매겨봤습니다. GPT-5 Mini가 검사를 병원 요금표에 매칭하고, 매칭이 안 되면 LLM이 추정하는 방식입니다. 추정 검사비는 의사 경로 $21,488, GPT-5

$13,245였습니다(진료비 포함 시 $23,288, $13,845). 매칭은 검증되지 않았습니다. 예를 들어 GPT-5의 MRA/CTA가 중복 계산됐을 수 있고, 의사의 피부생검 시술 코드가 빠져 있습니다. 이 숫자로 결론을 내리지는 않습니다.

출처와 재현성

- GPT-5 실행 trajectory: gpt5-trajectory/case_k0_0.json (SHA-256 `19cdc9815b028e97db4fa9609f12fde44c670761079e84806f302f0ecceb1222`)
- Astra max 실행: trajectory, Gatekeeper API 호출, run config
- Astra Gatekeeper: 주문 36개 재생, 분할 요청 31개
- Judge 실험: 거짓 설명, 근거 없는 합병증 (채점 호출 원본은 `runs/`)
- 증례 원문과 Gatekeeper 프롬프트: case 0, v6_fixed prompt

이 감사는 합성 증례 하나에 대한 저장된 실행의 정보 흐름 검토입니다. 전문가의 임상 판정, 실제 의사와의 비교 실험, 일부 정보를 뺀 재실행은 포함하지 않습니다. 따로 적지 않은 조건은 모두 한 번씩만 돌렸습니다. 원래의 진단과 비용 결과는 바꾸지 않았습니다.
